

Rapport technique

Segmentation comportementale et modélisation du bien-être sur 200 000
utilisateurs Instagram

Document de justification des choix méthodologiques

Gendell Janssens

Rush 4, Data Pro Max Bootcamp • Juillet 2026

Guide de lecture

Ce rapport justifie chaque choix technique du projet, dans l'ordre où les choix ont été faits. Il est écrit pour un lecteur data (consultant senior, direction technique), mais sans expertise supposée sur chaque méthode :

- **Chaque méthode est présentée avant d'être utilisée** dans un encadré « Méthode » en trois temps : ce que c'est, pourquoi on l'utilise ici, pourquoi ce choix plutôt qu'un autre.
- **Chaque graphique est guidé** : type de graphique, mode de lecture, observation, puis un encadré « Conclusion de l'étape » qui dit ce qu'on retient et pourquoi on peut passer à la suite.
- **Le code correspondant** se trouve dans le notebook (annexe A), organisé dans le même ordre que ce rapport : chaque section renvoie à une section du notebook.
- **Les pistes abandonnées** sont consignées en section 8 avec leur motif d'abandon, conformément au brief.

Plan du document

1. Objet et posture méthodologique

2. Données et audit qualité (arbitrage entre les deux fichiers, correction d'échelle, variables écartées)

3. Feature engineering (les 10 variables construites et leur piège principal)

4. Segmentation statistique (K-Means, choix de k, validation, interprétation)

5. Segmentation métier (les 4 personas et leur statut exact)

6. Volet prédictif (protocole, résultats, facteurs de confusion)

7. Audit critique (démonstration du caractère synthétique des données)

8. Pistes abandonnées

9. Reproductibilité et industrialisation

1. Objet et posture méthodologique

Le brief (Direction Innovation d'Instagram, sujet Rush 4) fixe deux objectifs :

- Chiffrer le lien entre les usages de la plateforme et trois indicateurs de bien-être : stress, sommeil, bonheur.
- Segmenter les utilisateurs selon leurs schémas d'usage, par clustering et/ou par prédiction.

Ce document répond à une question simple à chaque étape : pourquoi ce choix, et pourquoi pas un autre ? Il couvre :

- le choix des données et leur audit (section 2) ;
- la construction des variables d'analyse (section 3) ;
- la méthode de segmentation et le choix du nombre de groupes (sections 4 et 5) ;
- le protocole de modélisation prédictive et le test des facteurs de confusion (section 6) ;
- l'examen critique de la qualité des données (section 7) ;
- ce qui a été tenté puis abandonné, et pourquoi (section 8).

Posture. Toutes les relations rapportées sont des associations observées, jamais des causalités. Le mot « impact » du brief est traité comme une question à instruire, pas comme un acquis. Les données sont examinées avec méfiance avant d'être utilisées : la section 7 montre que cette méfiance était justifiée.

2. Données et audit qualité

2.1 Deux fichiers fournis : lequel utiliser ?

Deux CSV de 200 000 lignes et 58 colonnes chacun, aux schémas identiques. Avant d'en choisir un, nous avons comparé les deux fichiers ligne à ligne, utilisateur par utilisateur. Résultat :

- 52 colonnes sur 58 sont strictement identiques, dont toutes les variables d'usage et toutes les variables de bien-être.
- 6 colonnes divergent : `employment_status`, `education_level`, `relationship_status`, `has_children`, `weekly_work_hours`, `account_creation_year`. Toutes décrivent le profil, aucune ne décrit le comportement.

Décision. Travailler sur `instagram_usage_lifestyleSafe.csv` seul. Fusionner aurait dupliqué 52 colonnes identiques et imposé des choix arbitraires sur les 6 divergentes (impossible de savoir laquelle des deux versions est la bonne sans métadonnées). Les divergences sont conservées comme signal qualité : c'est exactement ce qu'on documenterait face à deux extractions CRM contradictoires chez un client.

2.2 Audit qualité et correction d'échelle

L'audit systématique donne :

Contrôle	Résultat	Décision
Valeurs manquantes	0 sur 11,6 millions de cellules	Aucune imputation nécessaire ; propreté suspecte, versée au dossier de la section 7
Doublons (lignes et user_id)	0	Rien à dédupliquer
Échelle du stress	0 à 40 dans les données ; la documentation annonce 0 à 10	La donnée prime sur la documentation : échelle corrigée à 0-40, aucune ligne supprimée
Bornes âge / sommeil / bonheur	13-65 ans ; 3-10 h ; 1-10	Plausibles ; présence de mineurs, traitée en overlay dédié
user_engagement_score	Corrélation de -0,53 avec les minutes actives	Variable opaque et contradictoire : exclue de toute modélisation

Pourquoi la correction d'échelle méritait un arrêt. Un contrôle de plage naïf, calé sur la documentation (0-10), aurait marqué 73 % des lignes comme invalides et pu conduire à une suppression massive de données parfaitement valides. La règle appliquée : quand la donnée et la documentation se contredisent, on vérifie la donnée (minimum observé 0, maximum 40, distribution continue et régulière), puis on corrige la documentation, pas la donnée.

3. Feature engineering

Méthode : feature engineering

Ce que c'est. Construire de nouvelles variables à partir des variables brutes, pour exprimer des notions que les compteurs bruts ne capturent pas. Exemple type : la distance et le temps d'un trajet ne disent rien de la vitesse, mais distance divisée par temps la donne.

Pourquoi ici. Les compteurs bruts (minutes, likes) mesurent surtout le volume d'usage. Pour segmenter des comportements, il faut aussi le style d'usage : la profondeur des sessions, la vitesse de défilement, la part de chaque type de contenu. Les ratios rendent en outre comparables des utilisateurs aux volumes très différents.

Pourquoi ce choix plutôt qu'un autre. Les 10 variables retenues couvrent quatre dimensions du comportement (intensité, mix de contenu, interaction, rythme) tout en restant lisibles une à une par un non-spécialiste. Nous avons écarté les combinaisons plus abstraites (composantes principales, scores composites) qui gagnent parfois en compacité mais perdent l'interprétabilité, indispensable pour des personas.

Variable construite	Formule	Ce qu'elle capture
minutes_per_session	minutes actives / sessions	Profondeur des sessions : visite éclair ou immersion
content_views_per_minute	(reels + stories vus) / minutes	Vitesse de défilement
interactions_per_minute	(likes + commentaires + clics pub) / minutes	Activité par unité de temps
reels_share, feed_share, messages_share	temps sur la surface / minutes totales	Répartition du temps entre les espaces
interaction_rate	interactions / contenus vus	Engagement actif ou consommation passive
followers_to_following_ratio	followers / following	Profil audience ou profil consommateur
sessions_per_hour	sessions / heures actives	Fréquence de consultation
avg_interactions_per_session	interactions / sessions	Engagement par visite

Le piège des ratios, identifié et neutralisé. Un ratio explose quand son dénominateur est proche de zéro. Un utilisateur actif 5 minutes par jour en 1 session affiche mécaniquement 11 « sessions par heure active », un chiffre qui évoque un utilisateur frénétique alors qu'il décrit un utilisateur quasi absent. Règle adoptée dans tout le projet : ne jamais interpréter un ratio sans lire le volume absolu à côté. La section 4.3 montre le cas concret où cette règle change l'interprétation d'un segment entier.

4. Segmentation statistique (K-Means)

4.1 Choix de la méthode et des variables

Méthode : clustering K-Means

Ce que c'est. Le clustering regroupe automatiquement les lignes qui se ressemblent, sans qu'on lui dise quels groupes chercher. K-Means, la méthode la plus utilisée, fonctionne ainsi : on choisit un nombre de groupes k , l'algorithme place k centres, affecte chaque utilisateur au centre le plus proche, recalcule les centres, et répète jusqu'à stabilité. Chaque groupe est alors résumé par son profil moyen, directement lisible.

Pourquoi ici. Le brief demande de segmenter les utilisateurs selon leurs schémas d'usage : c'est exactement ce que fait le clustering sur nos 10 variables comportementales.

Pourquoi ce choix plutôt qu'un autre. K-Means traite 200 000 lignes en quelques secondes et produit des profils moyens interprétables. Les alternatives ont été essayées et écartées : DBSCAN (méthode par densité) s'effondre en un seul méga-groupe plus du bruit sur des variables continues qui se chevauchent, ce que nous avons vérifié ; le clustering hiérarchique compare toutes les paires d'utilisateurs, ce qui est matériellement impraticable à 200 000 lignes ; les mélanges gaussiens n'apportent aucun gain démontrable pour une lisibilité moindre.

Méthode : standardisation (StandardScaler)

Ce que c'est. Ramener chaque variable à une moyenne de 0 et un écart-type de 1, pour que toutes pèsent pareil.

Pourquoi ici. K-Means raisonne en distances. Sans standardisation, une variable à grande échelle comme le ratio followers/following (qui monte à plusieurs centaines) écraserait les parts de contenu (entre 0 et 1) : les groupes ne refléteraient qu'une seule variable.

Pourquoi ce choix plutôt qu'un autre. C'est le prétraitement standard pour toute méthode à base de distances ; aucune alternative sérieuse ici.

Deux exclusions volontaires dans les variables de clustering, à justifier explicitement :

- **Pas de démographie.** Les segments doivent émerger du comportement, pas de l'âge ou du pays ; la démographie sert ensuite à décrire les groupes, pas à les construire.
- **Pas de bien-être.** Construire des groupes avec le stress puis « découvrir » qu'ils diffèrent en stress serait un raisonnement circulaire, sans valeur de preuve. Le bien-être est mesuré après coup, groupe par groupe : s'il diffère, c'est une information réelle. C'est la garantie de validité centrale de toute l'étude.

4.2 Choix du nombre de groupes (k)


Méthode : critères de choix de k

Ce que c'est. K-Means exige de fixer k à l'avance ; quatre mesures complémentaires évaluent chaque valeur candidate. L'inertie (méthode du coude) mesure la compacité des groupes : on cherche le point où ajouter un groupe ne rapporte presque plus rien. La silhouette compare, pour chaque utilisateur, sa distance à son propre groupe et au groupe voisin : elle va de -1 à 1, et plus elle est haute, mieux les groupes sont séparés. Calinski-Harabasz rapporte la dispersion entre groupes à la dispersion interne (plus haut = mieux). Davies-Bouldin mesure la ressemblance de chaque groupe avec son voisin le plus proche (plus bas = mieux).

Pourquoi ici. Le choix de k est LA décision contestable d'une segmentation ; nous le soumettons donc à quatre juges indépendants plutôt qu'à un seul.

Pourquoi ce choix plutôt qu'un autre. Utiliser plusieurs critères évite de choisir le k qui nous arrange. La silhouette est calculée sur un échantillon aléatoire de 8 000 utilisateurs car son calcul compare toutes les paires (la stabilité du résultat a été vérifiée sur plusieurs tirages).

k	Silhouette	Calinski-Harabasz	Davies-Bouldin	Inertie
2	0,551	3 141	0,836	57 551
3	0,180	2 627	1,648	48 375
4	0,176	2 132	1,604	44 531
5	0,148	1 843	1,708	41 708
6	0,141	1 655	1,848	39 389
7	0,141	1 523	1,771	37 396



Comment lire ce graphique. Deux courbes. À gauche, l'inertie en fonction de k : elle descend toujours, on cherche un coude net. À droite, la silhouette en fonction de k : on cherche le sommet. La ligne pointillée marque $k = 2$.

Ce qu'on observe. La silhouette vaut 0,551 à $k = 2$ puis s'effondre à 0,180 dès $k = 3$ et ne remonte jamais : au-delà de deux groupes, les frontières deviennent arbitraires. L'inertie ne montre aucun coude net après 2-3. Le tableau confirme : Calinski-Harabasz est maximal à $k = 2$, Davies-Bouldin minimal à $k = 2$.

Conclusion de l'étape. Les quatre critères convergent vers $k = 2$: la structure des comportements ne contient que deux groupes naturels. Nous avons envisagé $k = 4$ pour la richesse métier ; avec une silhouette de 0,176, ce choix aurait été indéfendable devant un pair. Le besoin de granularité est traité autrement en section 5, par une convention explicite plutôt qu'un k forcé.

4.3 Résultat et interprétation des deux groupes

K-Means final : $k = 2$, dix initialisations ($n_{init} = 10$), graine fixée ($random_state = 42$), appliqué aux 200 000 utilisateurs. Répartition : 187 918 utilisateurs (94,0 %) dans le groupe 0, 12 082 (6,0 %) dans le groupe 1.

Indicateur (moyenne)	Groupe 0 (94 %)	Groupe 1 (6 %)
Minutes actives / jour	200,5	5,4
Sessions / jour	11,0	1,0
Minutes / session	21,2	5,4
Âge moyen	38,5 ans	46,0 ans

Le cas d'école annoncé en section 3. Si on ne lisait que les ratios, le groupe 1 semblerait frénétique : 11,5 sessions par heure active, 16,8 contenus par minute. La lecture des volumes absolus renverse le diagnostic : 5 minutes par jour, une session. Ce sont des utilisateurs quasi inactifs, pas des hyperactifs ; leurs ratios explosent uniquement parce que leurs dénominateurs sont minuscules. L'enjeu n'est pas cosmétique : on ne recommande pas des « formats courts et percutants » à des gens qui n'ouvrent presque jamais l'application.

Méthode : PCA (analyse en composantes principales)

Ce que c'est. Nos utilisateurs vivent dans un espace à 10 dimensions (une par variable), impossible à dessiner. La PCA compresse ces 10 dimensions en 2 axes qui conservent le maximum de variation, ce qui permet de tracer chaque utilisateur comme un point.

Pourquoi ici. Vérifier visuellement que les deux groupes trouvés par K-Means sont réellement séparés, et pas un artefact de calcul.

Pourquoi ce choix plutôt qu'un autre. C'est l'outil standard de visualisation d'un clustering ; il ne sert ici qu'à la vérification, pas à l'analyse.




Figure T2. Projection PCA en deux dimensions, échantillon de 20 000 utilisateurs.

Comment lire ce graphique. Nuage de points : chaque point est un utilisateur, sa position résume ses 10 variables comportementales compressées en 2 axes. La couleur indique le groupe attribué par K-Means (bleu : actifs ; orange : minimaux).

Ce qu'on observe. Deux nuages distincts, avec très peu de recouvrement. La séparation est visible sur les deux axes à la fois : les groupes diffèrent sur plusieurs dimensions comportementales simultanément, pas sur une seule.

Conclusion de l'étape. La partition $k = 2$ est à la fois validée par les métriques et visible à l'œil nu : elle est solide. Reste à la rendre exploitable commercialement, objet de la section suivante.

5. Segmentation métier : les 4 personas

Le problème à résoudre. Un découpage 94 / 6 est statistiquement exact mais inutilisable : aucune équipe produit ne peut « cibler les 94 % ». Il faut plus de finesse, sans trahir la statistique qui vient de nous dire qu'il n'existe que deux groupes naturels.

Méthode : découpage en terciles

Ce que c'est. Les terciles sont les deux valeurs qui coupent une variable triée en trois groupes d'effectifs égaux. Ici, appliqués aux minutes actives quotidiennes du groupe actif : coupures à 145 et 249 minutes par jour.

Pourquoi ici. Découper le groupe actif (94 %) en trois niveaux d'intensité d'usage comparables en taille, donc pilotables : chacun pèse 31 % de la base.

Pourquoi ce choix plutôt qu'un autre. L'alternative aurait été de forcer K-Means à $k = 4$ et de présenter les quatre groupes comme une découverte. Avec une silhouette de 0,176, c'aurait été une découverte fictive. Le tercile assume son statut : c'est une convention de pilotage, comme des tranches de revenus, posée par-dessus une coupure statistique validée. Cette honnêteté méthodologique est un choix délibéré.

Le résultat, avec le bien-être mesuré après coup (jamais utilisé pour construire les groupes) :

Persona	Effectif	Min / jour	Sessions / j	Stress (0-40)	Bonheur (1-10)	Sommeil
P1 Minimaliste	12 082 (6 %)	5,4	1,0	4,1	8,1	7,0 h
P2 Occasionnel	62 812 (31 %)	86,3	4,7	10,1	6,2	7,0 h
P3 Régulier	62 602 (31 %)	197,2	10,8	21,2	5,5	7,0 h
P4 Intensif	62 504 (31 %)	318,7	17,4	31,8	4,3	7,0 h




Figure T3. Les quatre personas comparés sur l'usage et les trois indicateurs de bien-être.

Comment lire ce graphique. Quatre graphiques en barres, un par indicateur, les personas ordonnés du plus léger (gauche) au plus intensif (droite). La moyenne du groupe est affichée au-dessus de chaque barre.

Ce qu'on observe. Le gradient est strictement monotone sur le stress (4,1 puis 10,1 puis 21,2 puis 31,8) et sur le bonheur (8,1 puis 6,2 puis 5,5 puis 4,3), et parfaitement plat sur le sommeil (7,0 h partout).

Conclusion de l'étape. Le bien-être, mesuré après coup, ordonne les personas exactement comme l'intensité d'usage : c'est une validation externe forte du découpage. Le sommeil plat est un résultat nul assumé, cohérent avec la corrélation nulle mesurée en amont.

6. Volet prédictif

6.1 Pourquoi prédire, et avec quel protocole

Le brief autorise clustering ou prédiction ; nous faisons les deux, car la prédiction apporte trois choses que le clustering ne donne pas : un chiffrage précis du lien usage-stress, un classement des comportements qui comptent le plus, et un test formel des facteurs de confusion.

Méthode : régression linéaire

Ce que c'est. Trouver la meilleure relation en ligne droite entre des variables d'entrée et une cible. Ses coefficients se lisent directement : « une minute d'usage en plus est associée à tant de points de stress en plus ».

Pourquoi ici. C'est le modèle de référence (baseline) : simple, transparent, difficile à battre quand la relation est réellement linéaire.

Pourquoi ce choix plutôt qu'un autre. Toute modélisation sérieuse commence par une baseline interprétable ; les modèles complexes doivent prouver qu'ils font mieux qu'elle pour être retenus.

Méthode : Random Forest

Ce que c'est. Une forêt aléatoire construit des centaines d'arbres de décision sur des sous-échantillons des données et moyenne leurs prédictions. Elle capture les relations courbes et les interactions entre variables, ce qu'une droite ne peut pas faire.

Pourquoi ici. Servir de challenger à la régression linéaire : si la forêt fait nettement mieux, la relation n'est pas linéaire et il faut un modèle plus riche ; si elle ne fait pas mieux, la droite suffit.

Pourquoi ce choix plutôt qu'un autre. C'est le test de non-linéarité le plus simple à mettre en œuvre et à défendre. Paramètres : 25 arbres, profondeur 12, entraînement sur 50 000 lignes (taille vérifiée sans effet sur le résultat à plus ou moins 0,005 de R^2).

Méthode : protocole d'évaluation (train/test, R^2 , MAE)

Ce que c'est. On coupe les données en deux : 80 % pour entraîner les modèles (160 000 utilisateurs), 20 % gardés de côté pour les noter (40 000). Un modèle noté sur des données qu'il a déjà vues aurait une note artificiellement bonne. Deux notes : le R^2 , part de la variabilité du stress que le modèle explique (0 = rien, 1 = tout) ; la MAE, erreur moyenne de prédiction en points de stress, directement lisible sur l'échelle 0-40.

Pourquoi ici. Comparer équitablement les jeux de variables (usage seul, mode de vie seul, les deux) et les modèles (droite contre forêt).

Pourquoi ce choix plutôt qu'un autre. Avec 200 000 lignes indépendantes, un seul découpage 80/20 suffit statistiquement ; la validation croisée ajouterait du calcul sans changer les conclusions (vérifié : l'écart-type du R^2 entre plusieurs tirages est inférieur à 0,003).

6.2 Résultats

Modèle	R ² (test)	MAE	Lecture
Mode de vie seul, régression linéaire	0,000	10,23	Le mode de vie n'explique rien du stress
Usage seul, régression linéaire	0,715	5,05	L'usage explique 72 % de la variabilité du stress
Usage + mode de vie, régression linéaire	0,728	4,93	Le mode de vie n'ajoute presque rien (+0,013)
Usage seul, Random Forest	0,720	4,98	Aucune non-linéarité à exploiter
Minutes seules, régression à 1 variable	0,696	5,20	Le volume porte presque tout le signal




Figure T4. Comparaison des R² sur le jeu de test (40 000 utilisateurs).

Comment lire ce graphique. Graphique en barres : une barre par modèle, la hauteur donne le R² sur le jeu de test. Plus la barre est haute, plus le modèle explique le stress.

Ce qu'on observe. Trois barres racontent le résultat : le mode de vie seul est à zéro, l'usage seul à 0,715, et la forêt aléatoire (0,720) ne dépasse pas la droite. La combinaison usage + mode de vie (0,728) n'ajoute que 0,013.




Figure T5. Importance des variables selon la Random Forest (cible : stress).

Comment lire ce graphique. Barres horizontales : chaque barre est une variable d'entrée, sa longueur mesure sa contribution aux prédictions de la forêt. Les contributions somment à 1.

Ce qu'on observe. `daily_active_minutes_instagram` concentre 89 % de l'importance. Toutes les autres variables, y compris le mix de contenu et le style d'interaction, se partagent les 11 % restants.

Conclusion de l'étape. Trois conclusions défendables en soutenance. Un : la forêt ne bat pas la droite, donc la relation usage-stress est réellement linéaire ; à performance égale on retient le modèle interprétable, et c'est un choix documenté, pas une facilité. Deux : c'est la dose qui compte, pas le style ; le volume d'usage porte 89 % du signal. Trois : l'équation communicable au client est $\text{stress} = 3,4 + 0,0896 \times \text{minutes}$, soit +5,37 points de stress par heure quotidienne (R^2 test 0,696), à présenter comme une association.

6.3 Le test des facteurs de confusion

Méthode : facteur de confusion

Ce que c'est. Un facteur de confusion est une troisième variable qui influence à la fois la cause supposée et l'effet supposé, créant un lien apparent entre eux. Exemple classique : si les personnes surchargées de travail dormaient moins et utilisaient plus leur téléphone, les heures de travail créeraient un faux lien téléphone-sommeil.

Pourquoi ici. Le jury et le client poseront la question : « votre lien usage-stress n'est-il pas dû au mode de vie ? ». Nous y répondons par la comparaison de modèles ci-dessus plutôt que par un argument verbal.

Pourquoi ce choix plutôt qu'un autre. Comparer le R^2 des trois jeux de variables est le test le plus direct : si le mode de vie expliquait le stress, son R^2 serait nettement positif et son ajout à l'usage ferait bouger le résultat.

Verdict : R^2 du mode de vie = 0,000 et gain combiné de +0,013. Il n'existe aucune structure de confusion par le mode de vie dans ces données. Sur des données réelles, on s'attendrait à un signal (sport, heures de travail, sommeil interagissent avec le stress) ; son absence totale est en soi une anomalie, instruite en section 7.

Cibles secondaires, pour être complet : le sommeil est imprédictible depuis l'usage ($R^2 = 0,00$, résultat nul assumé) ; le bonheur l'est partiellement (R^2 linéaire = 0,16, cohérent avec sa corrélation de -0,37 avec l'usage). Vérifications annexes toutes négatives : le stress ne varie ni par pays (écart maximal 0,12 point entre les 10 pays) ni par type d'abonnement (0,14 point entre Premium et gratuit).

7. Audit critique : la preuve que les données sont synthétiques

Dire « les données sont artificielles » est une précaution ; le démontrer est un argument. Voici les empreintes du générateur, chacune vérifiable dans le notebook :

Vérification	Valeur mesurée	Attendu sur données réelles	Verdict
Corrélation minutes-stress	+0,834	0,1 à 0,2 dans la littérature	Relation plantée, trop propre
Corrélation stress-bonheur	-0,002	Autour de -0,5	Indépendance psychologiquement impossible
Corrélation minutes-sommeil	0,000	Faible mais non nulle	Sommeil généré comme bruit pur
Corrélation stress-sport, stress-travail	-0,001 / +0,001	Signaux modérés	Mode de vie purement décoratif
Corrélation minutes-engagement_score	-0,529	Positive	Score fourni contradictoire avec l'usage
Manquants / doublons	0 / 0 sur 200 000 lignes	Toujours quelques-uns	Aucun pipeline réel n'est aussi propre

Signatures de données synthétiques : des indépendances parfaites impossibles en données réelles




Figure T6. Trois signatures visuelles du générateur de données.

Comment lire ce graphique. Trois nuages de points. Dans chacun, un point est un utilisateur. De gauche à droite : sommeil contre usage, bonheur contre stress, score d'engagement contre usage. Un nuage sans aucune pente ni forme signale une absence totale de lien.

Ce qu'on observe. Les deux premiers nuages sont des rectangles uniformes : aucune pente, aucun lien, alors qu'on croise des variables qui devraient interagir (le bonheur et le stress d'une même personne !). Le troisième montre une pente négative : le score d'engagement fourni baisse quand l'usage réel monte.

Conclusion de l'étape. La recette du générateur se reconstitue : un stress fabriqué à partir des minutes plus un bruit ; un bonheur fabriqué indépendamment, aussi à partir des minutes ; un sommeil tiré au hasard autour de 7 h ; des variables de mode de vie purement décoratives. Conséquence pour l'interprétation : les tailles d'effet décrivent le générateur, pas le monde réel. Ce qui se transfère à des données réelles : la méthodologie, le cadre de segmentation et la logique de recommandation.

8. Pistes explorées puis abandonnées

Conformément au brief, les explorations non retenues sont conservées avec leur motif :

Piste	Motif d'abandon
Clustering direct à $k = 4$	Silhouette de 0,176 : frontières statistiquement arbitraires. Remplacé par la segmentation à deux niveaux (coupure validée + terciles assumés)
DBSCAN	S'effondre en un méga-groupe plus du bruit sur ces variables continues chevauchantes (vérifié empiriquement)
Clustering incluant les variables de bien-être	Raisonnement circulaire : des groupes construits sur le stress « découvrent » des écarts de stress. Rejeté malgré des séparations visuellement plus nettes
user_engagement_score comme variable	Score opaque, non documenté, et contradictoire avec l'usage mesuré (corrélation -0,53)
Prédiction du sommeil	R^2 de 0,00 : conservé comme résultat nul documenté plutôt que masqué
Fusion des deux CSV	52 colonnes identiques dupliquées ; divergences restantes non arbitrables sans métadonnées
Effets pays et abonnement	Vérifiés et nuls (écarts de 0,12 et 0,14 point de stress) ; rapportés pour complétude

9. Reproductibilité et industrialisation

9.1 Reproduire les résultats

- Environnement : Python 3.10 ou plus, pandas, scikit-learn 1.3 ou plus, matplotlib, seaborn. Le fichier requirements.txt du dépôt fixe les versions.
- Le notebook s'exécute de bout en bout en moins de 5 minutes sur une machine standard, dans Google Colab ou en local.
- Toutes les graines aléatoires sont fixées (random_state = 42) et l'étiquetage des groupes est rendu déterministe (le groupe 0 est toujours le majoritaire) : deux exécutions donnent exactement les mêmes chiffres.
- Coûts maîtrisés : silhouette sur échantillon de 8 000, Random Forest sur 50 000 lignes ; chaque allègement a été vérifié sans effet sur les conclusions.

9.2 Passer en production chez le client

- Affectation des nouveaux utilisateurs aux groupes existants par distance aux centroïdes, en batch trimestriel.
- Surveillance de dérive : distribution des distances aux centroïdes et poids de chaque persona dans le temps ; re-clustering annuel avec comparaison de la stabilité des affectations.
- Tableau de bord bien-être par persona (stress moyen, part de mineurs par niveau) alimenté à chaque scoring.
- Chaque action produit issue du rapport client est couplée à un test A/B : c'est l'étape qui transforme les associations mesurées ici en effets démontrés.

Annexes

- Annexe A : notebook Instagram_Wellbeing_Segmentation_v2.ipynb (dépôt GitHub), même plan que ce rapport. Workbook Colab : <https://colab.research.google.com/drive/1G8AKoqsw-zFK5mJtFfE1DklknY26cgoz>
- Annexe B : données Kaggle « Social Media User Analysis » (lien dans le README du dépôt) ; fichiers de 55 Mo exclus du dépôt Git, instructions de téléchargement fournies.